TRONSENTINEL

Cómo funciona nuestro modelo de riesgo de wallets TRON

Documentación técnica y explicativa del clasificador on-chain

MODELO	**tronsentinel-onchain-riskset-v0.6.1-20260928**
ARTEFACTO	**tronsentinel-wallet-shadow-v0.7.0-20260928**
AUTORES	**Madheline Katerine Torres Hallo** **Carlos Vladimir Ramírez Espinoza**
FECHA	**28 de septiembre de 2026**

Proyecto Integrador en Inteligencia Artificial - MIAR0545

1. Resumen y alcance

TronSentinel es un modelo supervisado que prioriza wallets de la red TRON para revisión humana. Analiza el comportamiento on-chain observado durante los 90 días anteriores a una fecha de evaluación y produce un score comparativo, una banda percentil y una recomendación operativa.

> Unidad de predicción
> La unidad evaluada es la wallet. Las transferencias son evidencia histórica para construir variables; el modelo no asigna riesgo a una transacción individual.



Todas las variables se calculan antes de la fecha índice; la blacklist no entra como predictor.

Pregunta que responde

¿Qué tan parecido es el comportamiento reciente de una wallet a los patrones observados antes de inclusiones confirmadas en la blacklist de Tether?

Qué incluye

- Wallets TRON con actividad confirmada en los contratos analizados de USDT y TUSD.
- Ventanas estrictas de 90 días anteriores a la fecha índice.
- Un único clasificador Gradient Boosting con calibración Platt.
- Explicación mediante contribuciones de variables y revisión humana en modo SHADOW.

Qué no incluye

- Scoring de transacciones individuales, reglas heurísticas, Bayes o un ensamble operativo paralelo.
- Bloqueo de wallets, congelamiento de fondos o decisiones automáticas.
- Una probabilidad absoluta de actividad ilícita o una certificación de licitud.

2. Diseño del dataset

1.854	400	1.454	38
filas de desarrollo	casos positivos	controles completos	variables on-chain

Construcción punto-en-tiempo

Cada caso utiliza una fecha índice anterior a su inclusión conocida en la blacklist. Para esa misma fecha se seleccionan controles activos y se reconstruyen únicamente eventos previos. Así, el modelo aprende señales disponibles en el momento de la evaluación y no información del futuro.

Partición	Filas	Positivas	Controles	Grupos
Entrenamiento	1.294	280	1.014	280
Validación	278	60	218	60
Test interno	282	60	222	60

Controles de integridad

- Separación cronológica por matchedCaseId: ningún grupo cruza entre train, validation y test.
- Cero cruces de direcciones entre casos, controles de desarrollo y holdout externo.
- Cero eventos posteriores a la fecha índice y cero valores no finitos.
- Historias truncadas o censuradas se excluyen del entrenamiento primario y son NOT_SCORABLE.
- La pertenencia a blacklist es la etiqueta objetivo; nunca se utiliza como predictor.

Etiqueta supervisada
Target 1: wallet con inclusión futura y fechada en la blacklist de Tether. Target 0: control activo sin inclusión conocida y con seguimiento suficiente.

3. Las 38 variables del modelo

Las variables resumen la actividad de cada wallet dentro de su ventana de 90 días. Se calculan con la misma semántica en entrenamiento y en evaluación en vivo.

Familia	Variables	Qué representa
Actividad	transferCount, transactionCount, activeDays, activeDayRatio, averageDailyTransfers	Frecuencia y presencia temporal
Dirección del flujo	inboundCount, outboundCount, inboundRatio, outboundRatio	Entradas y salidas
Montos	totalAmount, inboundAmount, outboundAmount, netFlowAmount, meanAmount, amountStd, amountCv, maxAmount	Volumen y dispersión monetaria
Contrapartes	uniqueCounterparties, uniqueInboundCounterparties, uniqueOutboundCounterparties, repeatedCounterpartyRatio	Diversidad y repetición
Concentración	topCounterpartyShare, counterpartyHhi, counterpartyEntropy, inboundTopCounterpartyShare, outboundTopCounterpartyShare	Dependencia de contrapartes dominantes
Autotransferencias	selfTransferCount, selfTransferRatio	Movimientos hacia la misma dirección
Activos	usdtTransferCount, tusdTransferCount, usdtAmount, tusdAmount	Actividad por token
Temporalidad	meanInterEventSeconds, interEventStdSeconds, interEventCv, burstiness, observedSpanDays, daysSinceLastTransfer	Ritmo, ráfagas y recencia

> Regla anti-leakage
> Ninguna variable contiene blacklist, label, riskScore, riskLevel ni un score previo. Todas las variables se derivan de eventos confirmados anteriores a indexAtUtc.

Características que más utiliza el modelo final

Variable	Importancia	Interpretación
daysSinceLastTransfer	49,66 %	Recencia de la última transferencia
meanAmount	44,38 %	Monto promedio transferido
repeatedCounterpartyRatio	3,60 %	Proporción de contrapartes repetidas
maxAmount	1,29 %	Monto máximo observado
inboundCount	0,50 %	Cantidad de transferencias entrantes

4. Entrenamiento, calibración y decisión

Clasificador

El modelo es un Gradient Boosting de 150 árboles de profundidad 1. Cada árbol aprende una corrección pequeña sobre el resultado acumulado. Los pesos de clase compensan la diferencia entre casos positivos y controles.

Parámetro	Valor	Propósito
Estimadores	150	Combinar correcciones simples
Profundidad	1	Mantener árboles interpretables y controlar sobreajuste
Learning rate	0,04	Aprendizaje gradual
Min. samples leaf	20	Evitar reglas basadas en muy pocos casos
Subsample	0,8	Introducir variación controlada
Seed	20260927	Reproducibilidad

Calibración Platt

La salida bruta del ensamble se transforma mediante una regresión logística de una sola dimensión. En forma simplificada: p = sigmoid(a × salida_bruta + b). Esta calibración mejora la correspondencia entre los valores del modelo y las frecuencias observadas en la muestra caso-control.

Umbral operativo

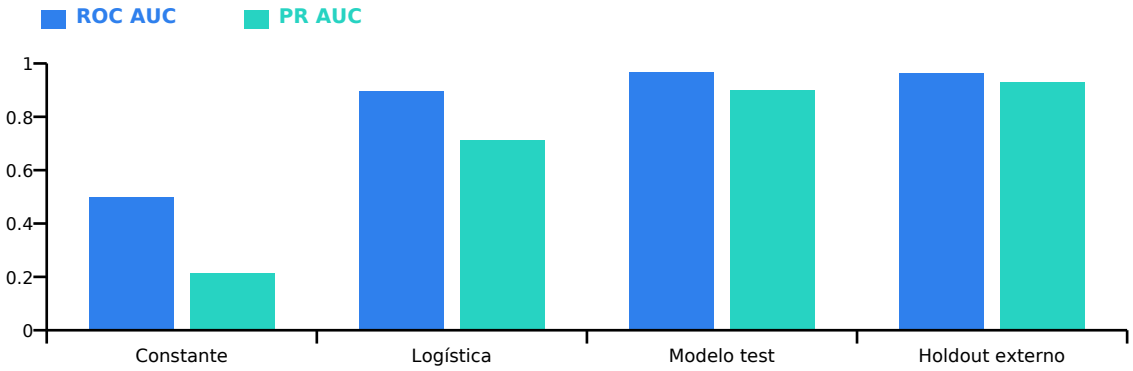
El umbral de revisión se seleccionó en validación con un límite máximo de falsos positivos del 5 %. El valor quedó congelado en 0,4288828974 antes de abrir el holdout externo.

> Dos escalas diferentes
> La probabilidad muestral decide si se recomienda revisión. El score 0-100 es un percentil frente a controles y describe posición relativa. Por eso una banda percentil elevada puede quedar por debajo del umbral de revisión.

Ejemplo de lectura

Salida	Ejemplo	Interpretación correcta
Score relativo	85/100	Mayor que el 85 % aproximado de los controles de referencia
Probabilidad muestral	7,64 %	Salida calibrada en la muestra caso-control
Umbral	42,89 %	Límite operativo congelado
Decisión	No requiere revisión	7,64 % está por debajo de 42,89 %

5. Validación y desempeño



Evaluación	ROC AUC	PR AUC	Brier	Recall	FPR
Test interno	0,967	0,899	0,052	0,817	0,036
Holdout externo	0,962	0,929	0,079	0,798	0,037
Regresión logística	0,895	0,712	0,135	0,600	0,054
Prevalencia constante	0,500	0,213	0,168	-	-

Holdout externo de una sola apertura

286	99	187	0,854
observaciones evaluables	positivas	controles completos	F1 externo

La matriz de confusión externa fue TN=180, FP=7, FN=20 y TP=79. Trece controles truncados quedaron fuera como no evaluables y un caso positivo sin control completo fue excluido antes del cálculo. El modelo y el umbral permanecieron congelados durante la evaluación.

Decisión de gobernanza
PASSED_EXTERNAL_HOLDOUT y APPROVED_FOR_SHADOW_DEPLOYMENT. El modelo está autorizado para observación y revisión humana, no para decisiones automáticas ni para interpretar su salida como probabilidad absoluta de producción.

6. Cómo se explica una evaluación

El modelo exporta la contribución de cada variable para una wallet concreta. Una contribución positiva aumenta la salida del clasificador; una negativa la reduce. Estas contribuciones explican el cálculo, pero no demuestran causalidad ni culpabilidad.

Ejemplo real del prototipo

Variable	Contribución	Lectura
meanAmount	-1,5170	El monto promedio redujo considerablemente el score
daysSinceLastTransfer	+1,2445	La recencia aumentó considerablemente el score
maxAmount	-0,3170	El monto máximo redujo moderadamente el score
repeatedCounterpartyRatio	+0,2474	La repetición de contrapartes aumentó ligeramente el score
inboundCount	+0,0818	Las entradas produjeron un aumento pequeño

> Calidad de la evidencia
> La wallet del ejemplo tenía un historial completo, pero solamente dos transferencias. El resultado es evaluable, aunque la evidencia conductual es limitada y debe leerse con cautela.

Ablaciones

Las pruebas de ablación confirman que el modelo depende materialmente de las variables monetarias y de recencia. Sin variables monetarias, el PR AUC de test baja de 0,899 a 0,700. Sin daysSinceLastTransfer baja a 0,761; sin ambas familias baja a 0,380.

Reglas para comunicar el resultado

- Decir 'score comparativo' o 'banda percentil', no 'probabilidad de delito'.
- Mostrar probabilidad muestral y umbral junto con la decisión de revisión.
- Traducir nombres técnicos de variables a frases comprensibles.
- Informar cuando existe poca actividad, truncamiento o cobertura incompleta.
- Conservar siempre la advertencia de modo SHADOW y revisión humana.

7. Despliegue, gobierno y limitaciones

Operación en modo SHADOW

La API recibe una dirección TRON, consulta TronGrid, reconstruye 90 días de transferencias, calcula las 38 variables y ejecuta el artefacto activo. La respuesta informa score, banda percentil, recomendación y contribuciones. Ningún resultado bloquea wallets ni modifica la blockchain.

Componente	Versión / política
Modelo	tronsentinel-onchain-riskset-v0.6.1-20260928
Artefacto SHADOW	tronsentinel-wallet-shadow-v0.7.0-20260928
Feature set	tron-wallet-onchain-1.0.0
Ventana	90 días
Umbral	0,4288828973999436
Acciones automáticas	No permitidas
Historias truncadas	NOT_SCORABLE

Limitaciones conocidas

- La prevalencia caso-control del dataset no representa la prevalencia real de producción.
- La etiqueta blacklist es un proxy de riesgo confirmado y puede omitir wallets aún no incluidas.
- El modelo cubre la actividad disponible de los contratos analizados; no representa toda la actividad posible en TRON.
- Las variables monetarias y de recencia concentran gran parte de la capacidad predictiva.
- Las wallets con muy poca actividad pueden producir resultados evaluables con evidencia limitada.
- El data drift requiere monitoreo y una futura política formal de reentrenamiento.

Trazabilidad

El dataset, el modelo, los reportes de entrenamiento, robustez, validación académica y holdout externo están versionados mediante SHA-256. El dataset de desarrollo congelado tiene hash 1039cb723b12f11b7793394cef430d5eea0e97cac6582bf277fa691c86558585.

> Conclusión
> TronSentinel demuestra que un único clasificador, entrenado con ventanas punto-en-tiempo y evaluado con un holdout externo, puede priorizar wallets TRON para revisión humana con bajo falso positivo. Su salida es una ayuda analítica, no una sentencia automática.

8. Reproducibilidad y referencias

Artefactos principales

Artefacto	Función
onchain-feature-dataset.csv	Dataset de desarrollo con 1.854 filas y 38 variables
onchain-feature-manifest.json	Esquema, conteos, splits y hashes
model-challenger-onchain.json	Clasificador exportado, calibrador y umbrales
training-report-onchain.json	Métricas por partición e importancia de variables
robustness-report.json	Bootstrap, ablaciones y estrés exploratorio
academic-validation-report.json	Baselines y ablaciones complementarias
external-holdout-report.json	Evaluación externa congelada
wallet-shadow-model-external-approved.json	Artefacto aprobado para SHADOW

Referencias metodológicas

- Friedman, J. H. (2001). Greedy Function Approximation: A Gradient Boosting Machine. Annals of Statistics, 29(5), 1189-1232.
- Platt, J. (1999). Probabilistic Outputs for Support Vector Machines and Comparisons to Regularized Likelihood Methods. Advances in Large Margin Classifiers.
- Brier, G. W. (1950). Verification of Forecasts Expressed in Terms of Probability. Monthly Weather Review, 78(1), 1-3.
- Saito, T. y Rehmsmeier, M. (2015). The Precision-Recall Plot Is More Informative than the ROC Plot When Evaluating Binary Classifiers on Imbalanced Datasets. PLOS ONE, 10(3).
- scikit-learn developers. GradientBoostingClassifier, LogisticRegression, calibration and model evaluation documentation.

Fuentes internas del proyecto

- Manifest del dataset de desarrollo risk-set v6.
- Reporte de entrenamiento del modelo v0.6.1.
- Reporte de robustez y validación académica.
- Manifiesto de congelamiento previo al holdout externo.
- Reporte de holdout externo y manifiesto de liberación SHADOW v0.7.

Documento preparado para el Proyecto Integrador en Inteligencia Artificial MIAR0545. Autores: Madheline Katerine Torres Hallo y Carlos Vladimir Ramírez Espinoza.